

Procesamiento Distribuido de Egresos Hospitalarios

- Pandas secuencial frente a Dask distribuido
- Registros nacionales 2020-2024
- Gerardo Rocafuerte - Jull Licoa - Marcos Echeverría
- Computación Paralela

Problema y contexto

- Cada fila representa un evento de egreso, no una persona identificada.
- El histórico multianual supera cinco millones de eventos.
- El ordenamiento y agrupamiento generan presión de memoria y CPU.
- Se evalúa una línea base Pandas y una versión Dask.

Datos y preparación

- Registros válidos procesados: 5,379,828.
- Años: 2020, 2021, 2022, 2023 y 2024.
- Cobertura: todas las provincias, incluida Galápagos.
- Variables homologadas: provincia, sexo, edad, CIE-10 y fechas.


Llave sintética y trayectorias

- Capítulo CIE-10 + provincia + sexo + rango etario.
- La llave representa un perfil epidemiológico, no identidad.
- Los eventos se ordenan por fecha.
- Reingreso crítico: nuevo ingreso entre 0 y 30 días.

Pipeline dual


- Pandas: carga completa, ordenamiento y agregación secuencial.
- Dask: lectura perezosa, shuffle, map_partitions y reducción.
- Ambas versiones usan la misma lógica y las mismas métricas.
- La validación exige diferencias iguales a cero.

Tiempo de ejecución




Mejor Dask: 2 workers, 89.54 s. Pandas: 87.63 s.

Memoria pico




La comparación considera el proceso Pandas y la suma de la memoria RSS de los workers. Spill-to-disk máximo de la mejor configuración: 0.00 MB.

Speedup y Ley de Amdahl




Speedup máximo observado: 0.979. Fracción secuencial estimada: 1.0000. El modelo clásico no incorpora el crecimiento del overhead.

Eficiencia paralela




La eficiencia disminuye cuando el overhead supera el trabajo útil por worker.

Mitigación de Data Skew



El salting distribuye las llaves de provincias densas sin separar los eventos de la misma llave.

K-anonimato



Las salidas publicables conservan únicamente grupos con $K \geq 50$. Porcentaje conservado: 96.8355 %.

Validación, conclusiones y recomendaciones

- Coincidencia Pandas-Dask: 100 % en las métricas agregadas.
- Mejor configuración: 2 workers.
- Las pruebas de 4 y 8 workers representan sobresuscripción y peor caso.
- No se empacan microdatos ni archivos Parquet.
- Se recomienda al INEC mantener enlaces estables, diccionarios abiertos y registros de cambios.